

Calidad del Aire en Quito

Clasificación mediante Machine Learning

Mateo Díaz | Universidad San Francisco de Quito

Contexto y Objetivos

Entendiendo la problemática ambiental en entornos urbanos y la necesidad de herramientas predictivas.

EL PROBLEMA DE LA CALIDAD DEL AIRE

Relevancia Urbana

La calidad del aire impacta directamente en la salud pública, la movilidad y la economía industrial.

Quito requiere sistemas capaces de estimar el estado atmosférico a partir de variables meteorológicas y contaminantes.

Propuesta de Solución

Implementación de un sistema de clasificación basado en aprendizaje supervisado (Machine Learning).

- Extracción de datos reales horarios.
- Evaluación de múltiples arquitecturas.
- Predicción binaria: "Buena" vs "No Buena".

METODOLOGÍA MODULAR



ETL & Datos

Integración de reportes mensuales de contaminantes (PM2.5, NO2, CO) y clima.



Preprocesamiento

Imputación por mediana, estandarización y One-Hot Encoding de variables temporales.



Entrenamiento

División 70/30 estratificada. Comparación de modelos lineales y ensambles.

| ARQUITECTURA DE DATOS REALES

- ✓ 805 registros horarios procesados.
- ✓ 17 columnas de predictores ambientales.
- ✓ Variables: PM10, NO2, O3, SO2, CO, Temperatura y Viento.
- ! Exclusión de PM2.5 como predictor para evitar fuga de información.



| REFORMULACIÓN A CLASIFICACIÓN BINARIA

315

CASOS "NO BUENA"

Manejo del Desbalance


La categoría inicial "Mala" solo contaba con **16 registros**.

Para garantizar la estabilidad del modelo, se unificaron las clases "Moderada" y "Mala" en una única etiqueta: **No Buena**.

Resultado: Un dataset más robusto con 490 registros "Buena" y 315 "No Buena".

MODELOS EVALUADOS

1. **Regresión Logística:** Modelo lineal base.
2. **Árbol de Decisión:** Reglas no lineales.
3. **Random Forest:** Ensamble por votación mayoritaria.
4. **Red Neuronal Densa:** Arquitectura multicapa (64-32-1) con dropout.



| DESEMPEÑO DE LOS MODELOS (ACCURACY)



Random Forest superó a la Red Neuronal, confirmando que los modelos de ensamble son altamente efectivos para datos tabulares moderados.

MÉTRICAS DE CLASIFICACIÓN

Modelo	Accuracy	F1 Clase Buena	F1 Clase No Buena	Macro F1-Score
Random Forest	0.7603	0.80	0.70	0.75
Red Neuronal	0.7355	0.78	0.67	0.72
Regresión Logística	0.7066	0.75	0.65	0.70

* El **Macro F1-score** es clave para evaluar el rendimiento equilibrado entre clases desbalanceadas.


ANÁLISIS DE RESULTADOS

¿Por qué Random Forest?

Los modelos basados en árboles capturan **relaciones no lineales** de manera más eficiente en datasets tabulares sin requerir volúmenes masivos de datos.

La Red Neuronal, aunque competitiva, se ve limitada por el tamaño moderado de la muestra (805 registros).

Conclusión: La complejidad del modelo no siempre garantiza un mejor resultado.



CONCLUSIONES Y FUTURO

- 🏆 Se desarrolló un pipeline completo y reproducible para Quito.
- 📈 Los modelos de ensamble son los más robustos para esta tarea.
- ▶▶ **Trabajo Futuro:** Incorporar validación temporal y métodos de explicabilidad (SHAP).

¿Preguntas?

Gracias por su atención

Mateo Díaz | mndiaz@estud.usfq.edu.ec

IMAGE SOURCES




<https://www.undp.org/sites/g/files/zskgke326/files/2025-02/undp-gctisd-airpollutionblog4pic1-2025.png>

Source: www.undp.org



<https://static.vecteezy.com/system/resources/thumbnails/077/819/986/large/3d-render-abstract-blue-neural-network-digital-data-connection-background-high-tech-glowing-nodes-lines-representing-artificial-intelligence-machine-learning-ideal-futuristic-backdrop-video.jpg>

Source: www.vecteezy.com



https://journal.gnest.org/system/files/graphical_abstract/gnest_07707/20250530054214/graphical_abstract-V1.jpg

Source: journal.gnest.org



https://static.vecteezy.com/system/resources/previews/012/198/177/large_2x/panoramic-view-of-the-north-central-part-of-the-city-of-quito-full-of-modern-buildings-during-a-sunny-morning-photo.jpg

Source: www.vecteezy.com