

Clasificación de la Calidad del Aire en Quito mediante Modelos de Machine Learning

Mateo Díaz
Ciencias de la Computación
Universidad San Francisco de Quito
Quito, Ecuador
mndiaz@estud.usfq.edu.ec

Resumen—Este trabajo presenta el desarrollo de un sistema de clasificación de calidad del aire para la ciudad de Quito usando técnicas de aprendizaje supervisado. A partir de reportes horarios reales de contaminantes atmosféricos y variables meteorológicas, se construyó un conjunto de datos integrado mediante un proceso de extracción, transformación y carga. Inicialmente se planteó una clasificación multiclase con las categorías *buena*, *moderada* y *mala*; sin embargo, debido al fuerte desbalance de la clase *mala*, el problema fue reformulado como una clasificación binaria: *buena* y *no buena*. Se compararon cuatro modelos: regresión logística, árbol de decisión, Random Forest y una red neuronal densa. Los resultados muestran que Random Forest obtuvo el mejor desempeño global, con un accuracy de 0.7603 y un Macro F1-score de 0.75. La red neuronal obtuvo resultados competitivos, aunque no superó al modelo basado en árboles. Este resultado sugiere que, para datos tabulares de tamaño moderado, los modelos de ensamble pueden ser más adecuados que redes neuronales densas simples.

Index Terms—Machine Learning, clasificación, calidad del aire, Quito, Random Forest, red neuronal, aprendizaje supervisado.

I. INTRODUCCIÓN

La calidad del aire es un problema relevante en ciudades urbanas debido a su relación con la salud pública, la movilidad, la actividad industrial y las condiciones meteorológicas. En este contexto, el uso de modelos de *machine learning* permite analizar mediciones históricas y construir clasificadores capaces de estimar el estado de la calidad del aire a partir de variables observadas.

Desde el punto de vista de aprendizaje estadístico, el problema puede formularse como una tarea de aprendizaje supervisado. Dado un conjunto de predictores X , se busca aprender una función $\hat{f}(X)$ que permita predecir una variable respuesta Y [1]. En este proyecto, los predictores corresponden a contaminantes secundarios, variables meteorológicas y variables temporales, mientras que la respuesta corresponde a una categoría de calidad del aire.

El objetivo principal de este trabajo es construir y evaluar modelos de clasificación para distinguir entre condiciones de calidad del aire *buena* y *no buena* en Quito. Además, se busca comparar modelos clásicos de aprendizaje supervisado con una red neuronal densa, siguiendo una metodología reproducible y generalizable para otros dominios aplicados.

Las principales contribuciones del proyecto son:

- construcción de un conjunto de datos real a partir de reportes mensuales horarios;
- definición de un flujo de preprocesamiento reproducible;
- comparación de modelos lineales, modelos basados en árboles y redes neuronales;
- análisis de métricas adecuadas para un problema con clases desbalanceadas.

II. MARCO TEÓRICO

II-A. Aprendizaje supervisado

En aprendizaje supervisado se dispone de observaciones de entrada y una variable objetivo. El objetivo es aprender una función que permita predecir la respuesta para nuevas observaciones. Formalmente, se asume una relación de la forma:

$$Y = f(X) + \epsilon, \quad (1)$$

donde $f(X)$ representa la información sistemática que los predictores aportan sobre la respuesta, y ϵ representa un término de error aleatorio [4]. Para este proyecto, Y es una variable categórica, por lo que el problema corresponde a clasificación.

II-B. Clasificación

En un problema de clasificación, la variable respuesta es cualitativa. Un clasificador $C(X)$ asigna una categoría a una observación a partir de sus predictores. En muchos casos, el modelo estima probabilidades condicionales $P(Y = k|X = x)$ y asigna la clase con mayor probabilidad [5]. En este proyecto, la tarea final consiste en clasificar cada hora de monitoreo como:

- *buena*;
- *no buena*.

II-C. Métricas de evaluación

Para evaluar clasificadores se utiliza la matriz de confusión, de la cual se derivan métricas como accuracy, precision, recall y F1-score. Para problemas con clases desbalanceadas, accuracy puede ser insuficiente, ya que un modelo puede obtener buen desempeño global ignorando una clase minoritaria. Por ello, en este trabajo se reporta también el Macro F1-score, que promedia el F1-score de cada clase con igual peso.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad (2)$$

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}, \quad (3)$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}. \quad (4)$$

II-D. Modelos considerados

Se consideraron cuatro modelos. La regresión logística se usó como modelo lineal base para clasificación binaria. Los árboles de decisión permiten capturar reglas no lineales mediante particiones sucesivas del espacio de variables. Random Forest extiende esta idea construyendo múltiples árboles sobre muestras bootstrap y subconjuntos aleatorios de variables; su predicción final se obtiene por votación mayoritaria [6]. Finalmente, se implementó una red neuronal densa con capas ocultas, activación ReLU, dropout y salida sigmoide para clasificación binaria, basada en el paradigma de redes multicapa entrenadas mediante retropropagación [7].

III. DATOS

III-A. Fuente y estructura original

Los datos utilizados provienen de reportes mensuales horarios de calidad del aire de Quito. Los archivos originales estaban separados por variable ambiental y tenían formato ancho mensual: cada fila representaba un día y cada columna correspondía a una hora del día. Este formato no es directamente utilizable para entrenar modelos de aprendizaje automático.

Las variables disponibles fueron:

- PM2.5;
- PM10;
- NO₂;
- O₃;
- SO₂;
- CO;
- temperatura;
- humedad relativa;
- precipitación;
- velocidad del viento.

III-B. Proceso ETL

Se implementó un proceso ETL con los siguientes pasos:

1. lectura de cada reporte mensual en CSV;
2. extracción de metadatos de mes y año;
3. conversión de formato ancho a formato largo horario;
4. construcción de una columna `datetime`;
5. agrupación por fecha y hora para eliminar duplicados;
6. unión de todas las variables ambientales mediante `datetime`;
7. generación de variables temporales: hora, día de la semana, mes e indicador de fin de semana.

El conjunto final procesado contiene 805 registros horarios y 17 columnas.

Tabla I: Distribución multiclase inicial

Clase	Registros
Buena	490
Moderada	299
Mala	16

III-C. Definición de la variable objetivo

Como los reportes no incluían directamente una columna AQI, se definió una variable objetivo inicial a partir de PM2.5. La formulación multiclase fue:

- *buena*: $PM2.5 \leq 15$;
- *moderada*: $15 < PM2.5 \leq 35$;
- *mala*: $PM2.5 > 35$.

Debido a que la clase *mala* contenía únicamente 16 registros, el problema fue reformulado como clasificación binaria:

- *buena*;
- *no buena*: combinación de *moderada* y *mala*.

La distribución binaria resultante se muestra en la Tabla II.

Tabla II: Distribución binaria final

Clase	Registros
Buena	490
No buena	315

Es importante señalar que PM2.5 no fue usado como predictor en el entrenamiento final, ya que la variable objetivo fue construida a partir de PM2.5. Incluirlo habría generado fuga de información.

IV. METODOLOGÍA

IV-A. Arquitectura del proyecto

El proyecto fue organizado siguiendo una arquitectura modular, separando carga de datos, limpieza, generación de variables, entrenamiento, evaluación y visualización. La estructura general fue:

- `data/raw`: datos originales;
- `data/processed`: datos procesados;
- `src/data_loader.py`: carga de archivos;
- `src/preprocessing.py`: limpieza e imputación;
- `src/features.py`: generación de variables;
- `src/models.py`: definición de modelos;
- `src/evaluate.py`: evaluación;
- `reports/figures`: gráficos de resultados.

IV-B. Preprocesamiento

Las variables numéricas con valores faltantes fueron imputadas usando la mediana. Posteriormente, las variables numéricas fueron estandarizadas. Las variables categóricas fueron imputadas con el valor más frecuente y codificadas mediante *one-hot encoding*.

Los predictores usados fueron:

- PM10, NO₂, O₃, SO₂, CO;
- temperatura, humedad, precipitación y velocidad del viento;
- hora, día de la semana, mes e indicador de fin de semana;
- estación.

IV-C. División entrenamiento-prueba

El dataset fue dividido en entrenamiento y prueba usando una proporción 70/30 con estratificación por clase. Esto permitió mantener proporciones similares de *buena* y *no buena* en ambos subconjuntos.

IV-D. Red neuronal

La red neuronal implementada fue una red densa para clasificación binaria con la siguiente arquitectura:

- capa densa de 64 neuronas con ReLU;
- dropout de 0.2;
- capa densa de 32 neuronas con ReLU;
- dropout de 0.2;
- capa de salida con una neurona y activación sigmoide.

Se utilizó *binary cross-entropy* como función de pérdida, Adam como optimizador, *early stopping* y pesos de clase para compensar el desbalance.

V. RESULTADOS

V-A. Resultados de clasificación binaria

La Tabla III muestra la comparación final entre los cuatro modelos evaluados.

Tabla III: Comparación de modelos sobre datos reales binarios

Modelo	Accuracy	F1 buena	F1 no buena	Macro F1
Regresión logística	0.7066	0.75	0.65	0.70
Árbol de decisión	0.6653	0.67	0.66	0.67
Random Forest	0.7603	0.80	0.70	0.75
Red neuronal	0.7355	0.78	0.67	0.72

Random Forest obtuvo el mejor desempeño general, con accuracy de 0.7603 y Macro F1-score de 0.75. La red neuronal alcanzó un resultado competitivo, con accuracy de 0.7355 y Macro F1-score de 0.72, pero no superó al modelo de ensamble.

V-B. Matriz de confusión del mejor modelo

La matriz de confusión de Random Forest se presenta en la Tabla IV.

Tabla IV: Matriz de confusión de Random Forest

	Pred. buena	Pred. no buena
Real buena	116	31
Real no buena	27	68

El modelo clasificó correctamente 116 de 147 registros reales de clase *buena*, y 68 de 95 registros reales de clase *no buena*.

VI. FIGURAS




Figura 1: Accuracy en datos reales para clasificación binaria.




Figura 2: Comparación de Macro F1-score en datos reales para la clasificación binaria.




Figura 3: Comparación del F1-score por clase en datos reales.




Figura 4. Flujo general del pipeline de Machine Learning

Figura 4: Flujo general del pipeline de Machine Learning: reportes CSV, ETL, preprocesamiento, entrenamiento y evaluación.

VII. DISCUSIÓN

Los resultados muestran que Random Forest fue el modelo más robusto para el dataset real. Esto puede explicarse por la naturaleza tabular del problema y por la capacidad de los modelos basados en árboles para capturar relaciones no lineales sin requerir grandes cantidades de datos. En contraste, la red neuronal densa tuvo un desempeño competitivo, pero probablemente estuvo limitada por el tamaño moderado del conjunto de datos.

La comparación también evidencia la importancia de no seleccionar modelos únicamente por su complejidad. Aunque las redes neuronales son modelos flexibles, no siempre superan a métodos clásicos en datos tabulares. Este resultado es consistente con la idea de que no existe un único método óptimo para todos los problemas, y que la selección del modelo debe depender del tipo de datos, el tamaño muestral, el desbalance de clases y las métricas de evaluación.

Otro punto importante fue la reformulación del problema. La clasificación multiclase inicial no era estable debido a la baja cantidad de registros de clase *mala*. Al convertir el problema a clasificación binaria, se obtuvo una tarea más balanceada y más adecuada para el volumen de datos disponible.

VIII. LIMITACIONES

El proyecto presenta varias limitaciones. Primero, el dataset corresponde a un período limitado, por lo que el modelo podría no generalizar a otros meses o estaciones climáticas. Segundo, la variable objetivo fue construida usando umbrales simplificados de PM2.5, lo cual no reemplaza un índice oficial completo de calidad del aire. Tercero, no se utilizó validación temporal, sino una división aleatoria entrenamiento-prueba. En series ambientales, una evaluación temporal podría ser más realista.

Además, aunque se excluyó PM2.5 como predictor para evitar fuga de información, esto hace que la tarea sea más difícil, ya que el modelo debe inferir la categoría de calidad del aire usando variables indirectas.

IX. CONCLUSIONES

Este proyecto desarrolló un pipeline completo de machine learning para clasificar la calidad del aire en Quito. Se construyó un dataset real a partir de reportes mensuales separados, se implementó un proceso de limpieza y transformación, y se compararon cuatro modelos de clasificación.

El mejor modelo fue Random Forest, con accuracy de 0.7603 y Macro F1-score de 0.75. La red neuronal obtuvo un desempeño competitivo, pero no superó al modelo basado en árboles. La principal conclusión es que, para un dataset tabular y de tamaño moderado, Random Forest fue más adecuado que una red neuronal densa.

Como trabajo futuro, se recomienda incorporar más meses de datos, realizar validación temporal, ajustar hiperparámetros y explorar métodos de explicabilidad como importancia de variables o SHAP.

REPRODUCIBILIDAD

El proyecto fue implementado en Python usando pandas, numpy, scikit-learn, matplotlib y TensorFlow/Keras. La arquitectura separa datos crudos, datos procesados, scripts de entrenamiento y resultados, facilitando la reproducción del experimento y su adaptación a otros dominios.

REFERENCIAS

- [1] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, *An Introduction to Statistical Learning: With Applications in Python*. Springer, 2023.
- [2] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. Springer, 2009.
- [3] D. Morales, *Statistical Learning: Lecture 1, Foundational Review*. Universidad San Francisco de Quito, 2026.
- [4] D. Morales, *Statistical Learning: Lecture 2, A Brief Introduction to Paradigms*. Universidad San Francisco de Quito, 2026.
- [5] D. Morales, *Statistical Learning: Lecture 4, Classification Problem*. Universidad San Francisco de Quito, 2026.
- [6] D. Morales, *Statistical Learning: Lecture 6, Decision Trees, Random Forests, and SVMs*. Universidad San Francisco de Quito, 2026.
- [7] D. Morales, *Statistical Learning: Lecture 7, Perceptrons and Neural Networks*. Universidad San Francisco de Quito, 2026.