

Propuesta de proyecto de Machine Learning

Clasificación de niveles de calidad del aire en Quito a partir de contaminantes atmosféricos y variables temporales

Mateo Díaz

Resumen

La calidad del aire es un problema ambiental y de salud pública con impacto directo en la población urbana. En Ecuador, las redes de monitoreo de calidad del aire se concentran principalmente en ciudades como Quito y Cuenca, lo que vuelve a Quito un caso de estudio factible y relevante. Además, existen estaciones de monitoreo activas en Quito reportadas por la red metropolitana y visibles en plataformas públicas de seguimiento de calidad del aire.

El objetivo de este proyecto es desarrollar un modelo de *machine learning* capaz de clasificar los niveles de calidad del aire en Quito a partir de variables como concentraciones de contaminantes atmosféricos y factores temporales. El problema se formulará como una tarea de clasificación supervisada, donde la variable objetivo podrá definirse como categorías de calidad del aire, por ejemplo *buena*, *moderada* y *mala*, o en una versión binaria como *aceptable* y *no aceptable*.

El proyecto busca aportar una herramienta de análisis predictivo con utilidad local, al permitir identificar patrones asociados a episodios de mala calidad del aire. Además de su relevancia práctica, el problema es apropiado para un curso de pregrado porque permite aplicar conceptos centrales de clasificación, evaluación de modelos y comparación entre métodos lineales y no lineales.

Metodología

Se utilizarán datos abiertos de calidad del aire obtenidos de fuentes públicas. Como fuente principal se considerarán registros de estaciones de monitoreo de Quito publicados a través de plataformas abiertas como AQICN o, de ser posible, fuentes institucionales locales. Las variables predictoras incluirán concentraciones de contaminantes como PM2.5, PM10, NO₂, O₃ y, si están disponibles, variables adicionales como hora, día de la semana, mes o estacionalidad.

El flujo de trabajo incluirá las siguientes etapas:

1. **Recolección y limpieza de datos**, eliminando registros incompletos o inconsistentes.
2. **Análisis exploratorio**, para identificar patrones temporales y relaciones entre contaminantes y niveles de calidad del aire.
3. **Construcción de la variable objetivo**, agrupando observaciones en clases de calidad del aire.
4. **Entrenamiento de modelos supervisados**, usando inicialmente regresión logística como modelo base por su interpretabilidad, y luego comparando con árboles de decisión y random forest, ya que estos métodos pueden capturar relaciones no lineales y suelen ser útiles cuando la frontera de decisión es compleja.
5. **Evaluación del desempeño**, mediante división en entrenamiento y prueba, y validación cruzada. Se usarán métricas como *accuracy*, *precision*, *recall*, *F1-score* y matriz de con-

fusión, dado que en problemas de clasificación no basta con medir únicamente exactitud, especialmente si las clases están desbalanceadas.

Desde el marco teórico del curso, este proyecto se apoya en la idea de construir una aproximación $\hat{f}(X)$ para predecir una variable respuesta categórica a partir de predictores observados. También permite contrastar la interpretabilidad de modelos lineales como la regresión logística con la flexibilidad de modelos basados en árboles y bosques aleatorios.

Alcance

El proyecto se limitará a datos de una o varias estaciones de monitoreo de Quito, en un período de tiempo acotado según disponibilidad de datos. No se plantea construir un sistema en tiempo real ni una plataforma operativa de alertas, sino un prototipo académico que permita analizar datos históricos y entrenar un clasificador reproducible.

Como resultado esperado, se obtendrá:

- un conjunto de datos limpio y documentado;
- un análisis exploratorio de la calidad del aire en Quito;
- la comparación de al menos tres modelos de clasificación;
- una discusión sobre cuáles variables tienen mayor influencia en la predicción; y
- una presentación oral en la que se expliquen problema, datos, metodología, resultados y limitaciones.

La principal limitación dependerá de la disponibilidad y calidad de los datos abiertos. Sin embargo, incluso con un alcance moderado, el proyecto sigue siendo valioso por su aplicación local, su factibilidad técnica y su alineación con los contenidos del curso de aprendizaje estadístico y *machine learning*.

Bibliografía

1. James, G., Witten, D., Hastie, T., & Taylor, J. *An Introduction to Statistical Learning with Applications in Python*. Springer, 2023.
2. Hastie, T., Tibshirani, R., & Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.
3. Morales, D. *Lecture 4: Classification Problem*. Universidad San Francisco de Quito, 2026.
4. Morales, D. *Lecture 6: Decision Trees, Random Forests, and SVMs*. Universidad San Francisco de Quito, 2026.
5. AQICN. *Quito Air Quality Monitoring Data*. Disponible en: <https://aqicn.org/city/ecuador/quito/centro/es/>